Proposta de pesquisa — Onde revisar primeiro

25 de setembro de 2026 · Giorgio Nicolas de A. Bertino · CDIA — UFPB

O problema

Agentes de IA (Claude Code, Codex, OpenHands) já escrevem patches inteiros, mas a revisão humana não acompanha esse volume. Um agente altera vários trechos em minutos. Revisar tudo com cuidado leva muito mais tempo, e o revisor não sabe por onde começar.

Passar nos testes não resolve. No SWE-bench, 10,7% das execuções aprovadas nos testes mostram um processo problemático: ciclos de regressão, tentativas às cegas, ausência de verificação (AgentLens). A dificuldade atinge dois perfis: o desenvolvedor experiente não tem tempo, e o iniciante não tem repertório para julgar.

A pergunta

> **Sinais da trajetória do agente conseguem indicar quais hunks de um patch têm mais chance de estar errados, melhor que sinais simples como tamanho e complexidade do hunk?**

A trajetória é o registro do que o agente fez: arquivos lidos, edições, comandos, testes. Exemplos de sinais candidatos:

- o hunk foi editado sem que o agente tivesse lido aquele trecho antes;
- a mesma região foi editada várias vezes, ou revertida e refeita;
- nenhum teste foi executado depois daquela edição;
- o agente declarou uma intenção e depois agiu de forma diferente.

O objetivo prático é dizer ao revisor "olhe estes trechos primeiro".

Por que ainda está em aberto

Duas revisões de literatura independentes (set/2026) não encontraram trabalho que use a trajetória para priorizar a revisão **dentro** do patch. Os trabalhos mais próximos, conferidos no arXiv, param antes:

Trabalho	O que faz	Onde para
AgentLens (2026)	Qualidade do processo; 10,7% de "Lucky Passes"	Avalia a execução inteira
TraceProbe (2026)	Anti-padrões em 2.500 trajetórias do SWE-bench Verified	Diagnóstico da execução inteira
Strained Coherence (2026)	Marca trechos da trajetória que antecedem falha (94% vs 46%, n=44)	Trechos da trajetória, não do patch
Early-Stage Review Effort (MSR 2026)	Com 20% da capacidade de revisão, captura 69% dos PRs de alto esforço	Nível de PR, sem trajetória
Vasconcelos et al. (TOCHI)	Destacar tokens com maior chance de edição acelera o programador	Apenas autocompletar, sem agente

A lacuna é juntar as duas pontas: sinais de trajetória (linha de AgentLens e TraceProbe) aplicados ao nível do hunk, para orientar a atenção humana (linha de Vasconcelos et al.). A área publica toda semana, então a checagem de novidade precisa ser refeita antes do experimento.

Dados e método (esboço)

O estudo usa trajetórias públicas, sem coletar dados de usuários e sem custo de geração.

1. **Dados:** trajetórias e resultados das submissões ao SWE-bench (swe-bench/experiments) e o conjunto de trajetórias SWE-agent da Nebius. Cada tarefa tem o patch do agente, o registro completo e o resultado dos testes.

2. **Definir "hunk errado":** é o ponto central, a validar com o orientador. Uma proposta: em patches que falham, reverter um hunk por vez e ver qual reversão muda o resultado dos testes.
3. **Extrair sinais por hunk** da trajetória (leitura prévia, número de edições, testes posteriores, reversões).
4. **Comparar com baselines simples:** tamanho do hunk, complexidade, ordem no diff, ordem aleatória.
5. **Métrica principal:** que fração dos hunks errados aparece entre os X% mais suspeitos (curva de esforço de revisão × erros encontrados).

Resultado esperado e contribuição

O resultado é uma frase mensurável: "revisando os X% de hunks mais suspeitos, encontram-se Y% dos erros", comparada aos baselines. Se os sinais não superarem os baselines, esse resultado negativo também é contribuição.

- **Contribuições:** (1) uma definição operacional de hunk errado em patches de agentes; (2) um conjunto de dados rotulado por hunk; (3) a primeira medição de sinais de trajetória para priorizar revisão.
- **Etapa 2 (futura):** estudo com usuários destacando os hunks de risco numa ferramenta de revisão, no formato do estudo de Vasconcelos et al.
- **Veículos possíveis:** MSR ou SBES/CBSoft para a etapa 1; preprint no arXiv (cs.SE).

Sobre mim e o que peço

Sou Giorgio Nicolas de A. Bertino, aluno do 1º período de Ciência de Dados e Inteligência Artificial (CDIA) da UFPB, e participo do Trilha UFPB. Desenvolvo o Catenary, uma IDE desktop para trabalhar com vários agentes de IA ao mesmo tempo, publicada em setembro de 2026 para Windows, macOS e Linux. Lido todos os dias com trajetórias e patches de agentes, e foi daí que surgiu a pergunta.

Peço orientação para:

- validar se a pergunta é relevante e ainda inédita;
- definir com rigor o que conta como "hunk errado" e como avaliar;
- formalizar como iniciação científica, se fizer sentido.

Referências

- Sahoo et al. AgentLens: Revealing The Lucky Pass Problem in SWE-Agent Evaluation. arXiv, 2026.
- Shu et al. What Resolve Rate Hides: Trajectory Structure Diagnostics for Coding Agents. arXiv, 2026.
- Pandya, Zhang, Lyu. Strained Coherence: A Pre-Failure Signal in Coding Agent Execution Trajectories. arXiv, 2026.
- Minh et al. Early-Stage Prediction of Review Effort in AI-Generated Pull Requests. MSR 2026.
- Vasconcelos et al. Generation Probabilities Are Not Enough: Uncertainty Highlighting in AI Code Completions. ACM TOCHI.
- Majgaonkar et al. Understanding Code Agent Behaviour: An Empirical Study of Success and Failure Trajectories. arXiv, 2025.